```
Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remount=True).
   1 #|wget -q http://archive.apache.org/dist/spark/spark-3.1.1/spark-3.1.1-bin-hadoop3.2.tgz
2 | tlar xf /content/drive/MyDrive/spark-3.1.1-bin-hadoop3.2.tgz
3 |pip install -q findspark
   1 !apt-get install openjdk-8-jdk-headless -qq > /dev/null
    2 os.environ["JAVA_HOME"] = "/usr/lib/jvm/java-8-openjdk-amd64"
3 os.environ["SPARK_HOME"] = "/content/spark-3.1.1-bin-hadoop3.2"
           3.1.1
1 from pyspark import SparkContext, SparkConf
2 from pyspark.sql import SparkSession
3 from pyspark.sql.types import StringType
4 from pyspark.sql.types import FPGrowth
5 import pyspark.sql.tynctions as F
6 import matplotlib.pyplot as plt
7 import findspark
8 import os
9 import os
9 import pyspark.sql.functions as F
10 from pyspark.sql.window import Window
11 from itertools import combinations
12 from functools import reduce
  1 conf = SparkConf().setAppName("gk")
2 sc = SparkContext.getOrCreate(conf=conf)
   1 def fi(path):
2    rdd = sc.textfile(path)
3     header = rdd.first()
4    rdd = rdd.filter(lambda line: line != header)
                items\_rdd = rdd.map(lambda \ line: line.split(',')) \\ unique\_items = items\_rdd.map(lambda \ x: \ x[2]).distinct().sortBy(lambda \ x: \ x.lower())
               output_path = "f1"
hadoop_conf = sc._jsc.hadoopConfiguration()
fs = sc._jvm.org.apach.hadoop_fs.FileSystem.get(hadoop_conf)
if fs.exists(sc._jvm.org.apach.hadoop.fs.Path(output_path)):
    fs.delete(sc._jvm.org.apach.hadoop.fs.Path(output_path), True)
                unique_items.coalesce(1).saveAsTextFile(output_path)
               # In ra 10 mục hàng đầu tiên
first_10_names = unique_items.take(10)
for name in first_10_names:
    print(name)
                1 def f2(path):
2     rdd = sc.textFile(path)
3     header = rdd.first()
4     rdd = rdd.filter(lambda line: line != header)
                 items_rdd = rdd.map(lambda line: line.split(','))
item_counts = items_rdd.map(lambda x: (x[2], 1)).reduceByKey(lambda a, b: a + b)
                # Sấp xếp các mục hàng theo số lần xuất hiện giảm dần sorted_items = item_counts.sortBy(lambda x: x[1], ascending=False)
               output_path = "f2"
hadoop_conf = sc._jsc.hadoopConfiguration()
fs = sc._jvm.org.apache.hadoop_fs.FileSystem.get(hadoop_conf)
if fs.exists(sc._jvm.org.apache.hadoop_fs.Path(output_path));
fs.delete(sc._jvm.org.apache.hadoop.fs.Path(output_path), True)
                sorted_items.coalesce(1).saveAsTextFile(output_path)
               top_items = sorted_items.take(10)
for item in top_items:
    print(item)
                # Lấy top 100 mục hàng được mua nhiều nhất
top_100_items = sorted_items.take(100)
item_names = [item[0] for item in top_100_items]
item_counts = [item[1] for item in top_100_items]
               plt.figure(figsize=(15, 6))
plt.bar(item_names, item_counts)
plt.xlabel('Mon hang')
plt.ylabel('56 lan mua')
plt.title('Top 100 mon hang duyc mua nhiều nhất')
plt.xtick(rotation=90)
plt.show()
  1 def f3(path):
2     rdd = sc.textFile(path)
3     header = rdd.first()
4     rdd = rdd.filter(lambda line: line != header)
c
               \label{eq:data_rdd} $$ \operatorname{rdd.map(lambda line: line.split(','))} \\ \operatorname{user} \operatorname{counts} = \operatorname{data_rdd.map(lambda x: (x[0], x[1]), 1)).reduceByKey(lambda a, b: a) \ \ \operatorname{map(lambda x: (x[0][0], 1)).reduceByKey(lambda a, b: a + b)} \\ \operatorname{sorted\_users} = \operatorname{user\_counts.sortBy(lambda x: x[1], ascending=False)} \\ 
               output_path = "f3"
hadoop_conf = sc._jsc.hadoopConfiguration()
fs = sc._jvm.org, apache.hadoop_fs.fileSystem.get(hadoop_conf)
if fs.exists(sc._jvm.org, apache.hadoop_fs.Path(output_path)):
    fs.delete(sc._jvm.org.apache.hadoop.fs.Path(output_path), True)
                 sorted_users.coalesce(1).saveAsTextFile(output_path)
                top_items = sorted_users.take(10)
for item in top_items:
    print(item)
               top_users = sorted_users.take(100)
user_names = [user[0] for user in top_users]
basket_counts = [user[1] for user in top_users]
               plt.figure(figsize=(20, 6))
plt.bar(user_names, basket_counts)
plt.xlabel('Người dùng')
plt.ylabel('Số lượng giố hàng')
plt.title('Top 100 người dùng mua nhiều giố hàng nhất')
plt.xticks(rotation=90)
```


```
3/15/24, 1:08 PM
                                                                                                                                                                                                                                                                    source ipynb - Colaboratory
            1 def f4(path):
2    rdd = sc.textfile(path)
3    header = rdd.first()
4    rdd = rdd.filter(lambda line: line != header)
                          \label{eq:data_rdd} $$ - rdd.map(lambda line: line.split(',')) $$ user_item_counts = data_rdd.map(lambda x: (x[0], x[2])).distinct().map(lambda x: (x[0], 1)).reduceByKey(lambda a, b: a + b) $$ user_most_items = user_item_counts.sortBy(lambda x: x[1], ascending=False).first() $$
                       print("Người dùng mua nhiều món hàng phân biệt nhất:")
print("Mã người dùng:", user_most_items[0])
print("Số lượng món hàng:", user_most_items[1])
                          item\_user\_counts = data\_rdd.map(lambda x: (x[2], x[\theta])).distinct().map(lambda x: (x[\theta], 1)).reduceByKey(lambda a, b: a + b) \\ item\_most\_users = item\_user\_counts.sortBy(lambda x: x[1], ascending=False).first()
                         print("Món hàng được mua bởi nhiều người dùng nhất:")
print("Tên món hàng:", item_most_users[0])
print("Số lượng người mua:", item_most_users[1])
                         cutput_path = "f4"
if sc._jvm.org.apache.hadoop.fs.FileSystem.get(sc._jsc.hadoopConfiguration()).exists(sc._jvm.org.apache.hadoop.fs.Path(output_path)):
    sc._jvm.org.apache.hadoop.fs.FileSystem.get(sc._jsc.hadoopConfiguration()).delete(sc._jvm.org.apache.hadoop.fs.Path(output_path), True)
output_de sc.parallelize(user_most_items + item_most_users)
output_dc.oalesce(1).saveAsTextFile(output_path)
            1 path = "/content/drive/MyDrive/baskets.csv"
            1 f1(path)
                   inipath)

abrasive cleaner
artif. sweetener
baby cosmettics
bags
baking powder
bathroom cleaner
beef
berries
beverages
bottled beer

UHT-milk
vinegar
waffles
whipped/sour cream
white bread
white wine
whole milk
yogurt
zwieback
```


1 f2(path)

('whole milk', 2502)
('other vegetables', 1898)
('rolls/buns', 1716)
('soda', 1514)
('yogunt', 1334)
('root vegetables', 1071)
('tropical fruit', 1832)
('bottled water', 933)
('sausage', 924)
('citrus fruit', 812)





('2271', 11) ('1379', 11) ('4338', 11) ('3737', 11) ('2193', 11) ('1574', 10) ('4217', 10) ('4217', 10) ('2524', 10) ('2394', 10) ('4864', 10)



Người dùng mua nhiều món hàng phản biệt nhất: Mã người dùng: 2851 Số lượng món hàng: 26 Món hàng được mua bởi nhiều người dùng nhất: Tên món hàng: whole milk Số lượng người mua: 1786

```
def create_basket(self):
    # Doc file và tạo baskets
    df = self.spark.read.csv(self.basket_file).withColumn("STT", F.monotonically_increasing_id())
    df = df.withColumn("Basket", F.split(F.col("_c0"), ", "))
    df = df.select("STT", "Basket")
    return df
         def frequency(self):
    # Tim danh sách frequency
    windowSpec = Window.orderBy("item")
    items_df = self.basket.select("Basket").withColumn("item", F.explode("Basket")).groupBy("item").count()
    items_df = items_df.withColumn("id", F.row_number().over(windowSpec))
    items_df = items_df.select("id", "item", "count")
    items_df = items_df.filter(F.col("count") > 1).orderBy(F.lower(F.col("item")))
    return items_df
         def hash_function(self, pair, item_ids):
# Tinh giá tri hash cho từng pair
sum_hash = item_ids.get(pair[0], 0) + item_ids.get(pair[1], 0)
return sum_hash % self.hash_table_size
         def create_hash_df(self, pairs, item_ids):
    # Xử lý bằng bằm
               # Cập nhật bảng băm
for row in hash_table_df.collect():
   id_bucket = row["id_bucket"]
   self.hash_table[id_bucket] = 1
              def find_frequent_pairs(self):
    frequency_df = self.frequency()
    exploded_df = self.basket.select("STT", F.explode("Basket").alias("item"))
              # Loai bô các item không nằm trong frequency_df
exploded_df_alias = exploded_df.alias("edf")
modified_df = exploded_df_alias.join(
                    frequency_df,
exploded_df_alias["item"] == frequency_df["item"],
               ).groupBy("STT").agg(F.expr("collect_list(edf.item) as Basket"))
              # Hash table (Xú lý báng bám)
item_ids = self.frequency_df.select("item", "id").rdd.collectAsMap()
df_nash_table = self.create_hash_df(pairs_with_freq, item_ids)
               # Count all pairs (Tim frequent tất cả các pair thoả mãn điều kiện)
df_hash_table = df_hash_table.groupBy("item1", "item2", "id_bucket").count()
df_hash_table = df_hash_table.withColumnRenamed("count", "frequency")
filtered_pairs_df = df_hash_table.filter(F.col("frequency") > (self.s * self.basket.count()))
```